



Face recognition using BP

Lukáš Šurín

Motivácia

- Login systém
- Verifikovanie totožnosti
- Pomoc pri identifikovaní zločinov
- Označenie fotiek FB





Výhody & Nevýhody

- Jednoduchosť (nekooperatívny prístup)
- Masové využitie
- Efektívnosť
- Spoľahlivosť



Cieľ

- Rozpoznávanie tvárí pomocou vrstevnatých neurónových sietí s algoritmom spätného šírenia.
- Spoľahlivosť takéhoto rozpoznávania



Problémy

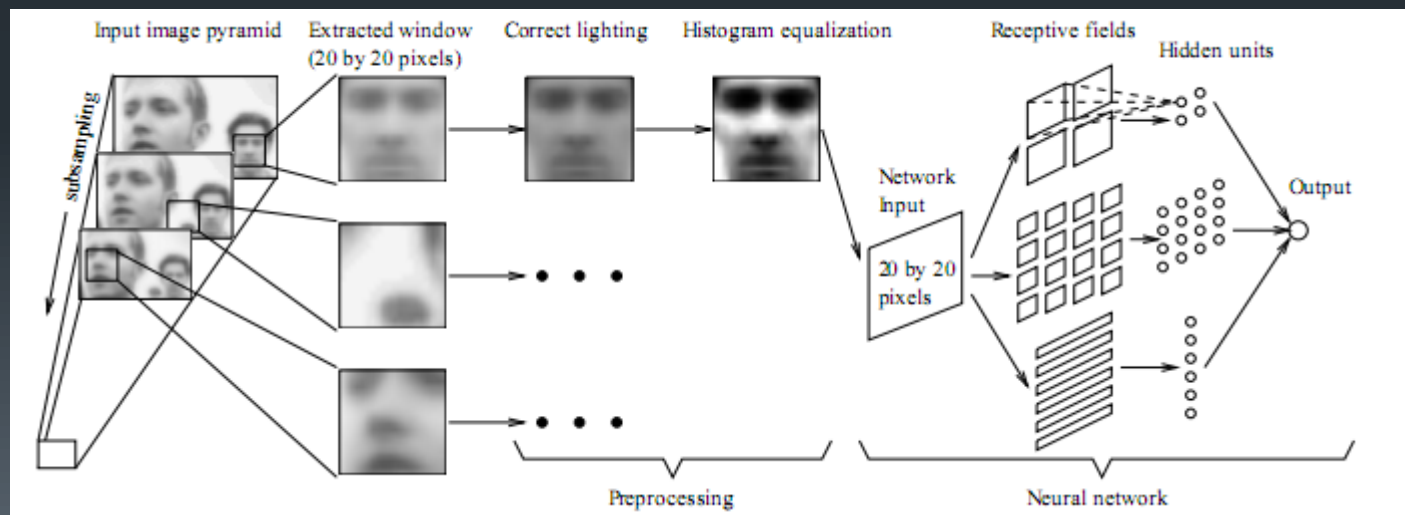
- Detekcia tvárí z obrázkov
- Získanie databáze fotiek so vzorkami rôznych výrazov na vytrénovanie NS.
- Konzistentnosť fotiek, normalizácia
- Veľkosť siete, veľkosť vstupného priestoru a riedkosť siete

Detekcia tváre



Detekcia tváre

- V prvom prípade nutnosť detekovať tvár v obrázku.
- Na detekciu je taktiež možné využiť NS (nutnosť vlastniť trénovaciu množinu rôznych tvárí). Výstup 0 alebo 1.
- Prevedenie na čiernobiely obrázok, zmenšovanie obrázku, prechod obrázkom, úprava svetelnosti a ekvalizácia.





Problémy detekcie tváre


- Rôzne natočené tváre
- Nekvalitné fotky s nevhodným osvetlením, rozmazané
- Zakryté tváre

Dáta

- Fotky tvárí získane z internetu.
- 40 ľudí, každý 10 rôznych výrazov.
- Upravené, zrotované.
- Čiernobiele
- Vycentrované

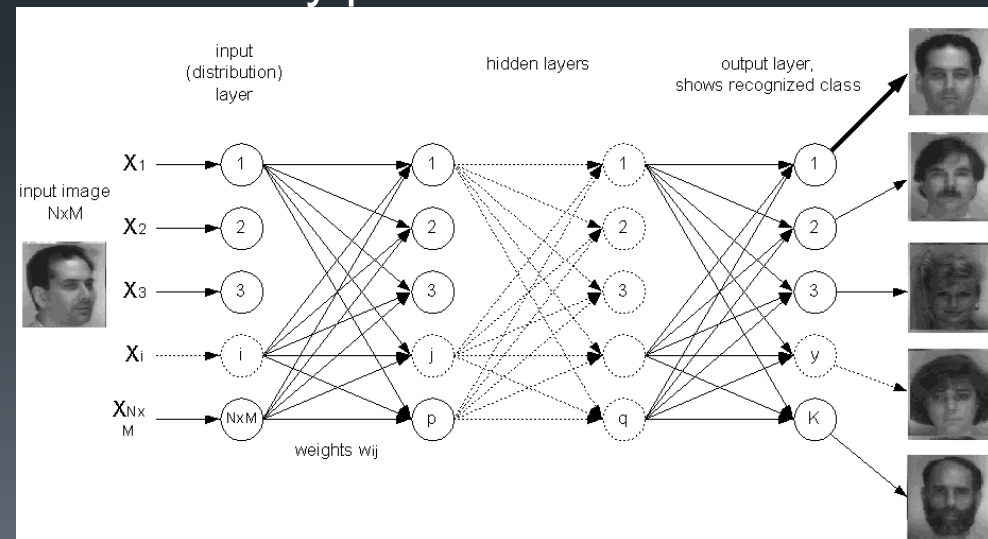


Taktiež bola dostupná množina znormalizovaných tvárí (zmenšené, štvorcové a orezané).



Neurónová sieť a jej veľkosť

- Obrázky z nenormalizovanej množiny sú veľkosti $46 \times 56 \Rightarrow 2567$ neurónov na vstupnej vrstve (pre každý pixel jeden neurón).
- Hodnoty pixelov sú z rozsahu 0-255.
- Veľkosť vstupného priestoru máme teda 255^{2567} . V takomto priestore máme 400 vstupov (vektorov) na rozpoznanie
- Výstupná vrstva má počet neurónov rovný počtu rozpoznávaných ľudí.



Učenie siete

- Na naučenie siete využívam program NeuroFace, ktorý je možné stiahnuť z internetu zadarmo.
- 200 obrázkov využijem na naučenie. Ostatok na otestovanie.
- V programe načítam obrázky tvárí, ktoré chceme rozpoznať.
- Nastavím počet vrstiev na 2 (vnútorná a výstupná), kde vnútorná bude obsahovať 30 neurónov a výstupná zase 40 neurónov (každý neurón jeden človek).
- Na tejto množine sieť naučím vybratím možnosti MLP (multi-layer perceptron). Po naučení je možné otestovať v koľkých vzoroch sa sieť zmýli.
- Počet omylov na testovacej množine veľkosti 200 je 9 => 4.5% chybovosť. Učenie trvá približne 76s.



PCA – Principal Component Analysis

- Štatistická metóda, ktorá používa ortogonálnu transformáciu na transformovanie korelovaných vektorov na nekorelované. Získanie najpríznačnejších vlastností.
- Metóda slúži na zníženie dimenzie vstupných dát.
- Vytvárame bázu nového priestoru. Báza popisuje najvýznamnejšie znaky.
- Pri rozpoznávaní tváre sa využíva veľmi často.

PCA a učenie siete

- Vstupné obrázky sú silne korelované. Mnoho pixelov v obrázkoch je korelovaných.
- Máme 200 rôznych trénovacích obrázkov. Každý obrázok je ako keby vstupným vektorom do siete => máme maticu U veľkosti $200 * 2567$.
- Vypočítame vlastné vektory kovariačnej matice, ktoré budú tvoriť bázu nového priestoru. Každému vlastnému vektoru zodpovedá vlastné číslo, ktoré určuje variáciu na tomto mieste. Po vybraní vlastných vektorov s čo najväčšími vlastnými číslami dostávame našu novú bázu.

pokračovanie

- Kovariančnú maticu máme teda veľkosti 2567×2567 , čo je strašne veľa. Preto sa používa Karhunen-Lowe transformácia, ktorá vypočíta vlastné vektory θ nad maticou 200×200 .
- Takto získaný vektor ešte prepočítame pre originálnu maticu (vynásobením s U^T sa stáva vlastným vektorom pre originálnu kovariančnú maticu).
- Učenie siete prevedením PCA analýzy by bolo rýchlejšie pričom kvalita rozpoznávania by sa ani nezmenila.

Najvýznačnejšie vektory, najpríznačnejšie znaky

